

Lab4 Diabetic Retinopathy Detection

邱以中

311551040

1. Introduction

在這次 lab4 中，我們的目標是要預測眼部的黃斑部病變，輸入會是眼睛的 image，輸出則是 5 個 label(0~4)，代表黃斑部病變的嚴重程度，我們要做的事就是根據給定的影像、label，訓練 resnet18, resnet50 (包含 pretrained)的 model 來進行正確的預測。

2. Experiment setups

A. The details of your model (ResNet)

● Pretrained

使用 torchvision 提供的 resnet18, resnet50 model, 並載入 pretrain 好的 weight，然後為了符合我們要預測的 5 個類別，會將原本最後一層的 FC 層替換掉，改成 output 為 5 的 FC 層

```
178 class ResNet18_pretrain(nn.Module):
179     def __init__(self, num_classes) -> None:
180         super().__init__()
181         self.model = resnet18(pretrained=True)
182         self.model.fc = nn.Linear(self.model.fc.in_features, num_classes)
183
184     def forward(self, x):
185         x = self.model(x)
186         return x
187
188 class ResNet50_pretrain(nn.Module):
189     def __init__(self, num_classes) -> None:
190         super().__init__()
191         resnet = resnet50(pretrained=True)
192         self.features = nn.Sequential(*list(resnet.children())[:-1])
193         self.fc = nn.Linear(resnet.fc.in_features, num_classes)
194
195     def forward(self, x):
196         x = self.features(x)
197         x = x.view(x.size(0), -1)
198         x = self.fc(x)
199         return x
```

● Without pretrained

在 without pretrain 的版本中，我則是嘗試手寫一個完整的 resnet 架構，在 resnet50 中使用 bottleneck block 來進行建構，在 resnet18 中使用 basic block 來進行建構，並將每個 block 的 input 與 output 進行相加來建構殘差網路，並且為了讓 input 與 output 的 dimension 保持一致，在每個 block 當中都會使用 downsample 來檢查 input channel 與

output channel * expansion 是否有一致，若是沒有則是用 1x1 的 convolution 來達成 升維/降維 的操作。

Bottleneck block

```
5 # resnet50 sub block
6 class BottleneckBlock(nn.Module):
7
8     expansion = 4
9     def __init__(self, in_channels, out_channels, stride=1):
10         super().__init__()
11         self.conv1 = nn.Conv2d(in_channels, out_channels, kernel_size=1, bias=False)
12         self.bn1 = nn.BatchNorm2d(out_channels)
13         self.conv2 = nn.Conv2d(out_channels, out_channels, kernel_size=3, stride=stride, padding=1, bias=False)
14         self.bn2 = nn.BatchNorm2d(out_channels)
15         self.conv3 = nn.Conv2d(out_channels, out_channels*self.expansion, kernel_size=1, bias=False)
16         self.bn3 = nn.BatchNorm2d(out_channels*self.expansion)
17         self.relu = nn.ReLU(inplace=True)
18
19         if stride != 1 or in_channels != out_channels*self.expansion:
20             self.downsample = nn.Sequential(
21                 nn.Conv2d(in_channels, out_channels*self.expansion, kernel_size=1, stride=stride, bias=False),
22                 nn.BatchNorm2d(out_channels*self.expansion)
23             )
24         else:
25             self.downsample = nn.Identity()
26
27     def forward(self, x):
28         identity = x
29
30         out = self.conv1(x)
31         out = self.bn1(out)
32         out = self.relu(out)
33
34         out = self.conv2(out)
35         out = self.bn2(out)
36         out = self.relu(out)
37
38         out = self.conv3(out)
39         out = self.bn3(out)
40
41         identity = self.downsample(identity)
42
43         out += identity
44         out = self.relu(out)
45         return out
```

Basic block

```

47 # resnet18 sub block
48 class BasicBlock(nn.Module):
49     expansion = 1
50     def __init__(self, in_channels, out_channels, stride=1):
51         super().__init__()
52         self.conv1 = nn.Conv2d(in_channels, out_channels, kernel_size=3, stride=stride, padding=1, bias=False)
53         self.bn1 = nn.BatchNorm2d(out_channels)
54         self.relu = nn.ReLU(inplace=True)
55         self.conv2 = nn.Conv2d(out_channels, out_channels, kernel_size=3, stride=1, padding=1, bias=False)
56         self.bn2 = nn.BatchNorm2d(out_channels)
57
58         if stride != 1 or in_channels != out_channels:
59             self.downsample = nn.Sequential(
60                 nn.Conv2d(in_channels, out_channels, kernel_size=1, stride=stride, bias=False),
61                 nn.BatchNorm2d(out_channels)
62             )
63         else:
64             self.downsample = nn.Identity()
65
66     def forward(self, x):
67         identity = x
68
69         out = self.conv1(x)
70         out = self.bn1(out)
71         out = self.relu(out)
72
73         out = self.conv2(out)
74         out = self.bn2(out)
75
76         identity = self.downsample(identity)
77
78         out += identity
79         out = self.relu(out)
80
81         return out

```

B. The details of your Dataloader

在 init 階段，我們會根據不同的 mode，讀取相對應的 csv 檔，取得 training/testing 的 image 檔名與其對應的 label

```

19
20 class RetinopathyLoader(data.Dataset):
21     def __init__(self, root, mode):
22         """
23         Args:
24             root (string): Root path of the dataset.
25             mode : Indicate procedure status(training or testing)
26
27             self.img_name (string list): String list that store all
28             self.label (int or float list): Numerical list that stor
29         """
30         self.root = root
31         self.img_name, self.label = getData(mode)
32         self.mode = mode
33

```

在 getitem 這個 function 中，我們會定義如何讀取資料(image,label)，我們會根據 index 取得 image 檔名與 label，並根據檔名讀取 image，之後再對 image 做 transform 然後回傳。

```

"""
Step4: Return processed image and label
"""
path = os.path.join(self.root, f'{self.img_name[index]}.jpeg')
img = Image.open(path)
width,height = img.size
if self.mode == "train":
    transform = transforms.Compose([
        # transforms.CenterCrop((height,height)),
        transforms.RandomHorizontalFlip(0.5),
        transforms.RandomVerticalFlip(0.5),
        # transforms.Resize((512, 512)),
        transforms.ToTensor()
    ])

elif self.mode == "test":
    transform = transforms.Compose([
        # transforms.CenterCrop((height,height)),
        # transforms.Resize((512, 512)),
        transforms.ToTensor()
    ])


img = transform(img)
label = self.label[index]

return img, label


```

C. Describing your evaluation through the confusion matrix


- Resnet18




- Resnet18 pretrained



● Resnet50



● Resnet50 pretrained



由 confusion matrix 的結果可以發現，如果沒有 pretrain，在短短的幾個 epoch 中 model 其實沒辦法學得很好，幾乎對於所有輸入

model 都傾向輸出 label 0。而在 pretrained 的版本中，model 則是能較好的預測出不同的結果，不過可以發現在 predict 的結果中幾乎都沒有 label1，推測是因為 label1 的資料太少，所有 model 沒有辦法很好的進行學習。

3. Data Preprocessing

A. How you preprocessed your data?

在對 image 做 preprocess 時，我們會對 image 做 transform，對 image 做 center crop 去除周圍的黑色背景，保留重要的區域，將所有 image resize 到同樣大小，並在最後使用 totensor 將 image 轉換成 tensor 型態。除此之外，在 training 時我也有使用 random flip 來做資料增強。

值得一提的是，在讀取資料時，我也有發現在 training image 中有資料損毀的情況發生，導致在讀取資料階段發生錯誤，因此我有事先找出資料損毀的圖片，並將他們的圖片與對應的 csv 資料進行刪除，就我發現的有這三張圖片。

```
20  
21 # 38790 right  
22 # 29126 right  
23 # 8421 left  
24
```


B. What makes your method special?

- 使用 center crop 讓 model 能關注在圖片中的主要部分，center crop 的大小設置為原圖片的 height 能最大程度保留眼睛的部分。
- 在 training 階段使用 random flip 來增加 model 的泛化能力，避免 overfitting。
- 事先去除損毀的圖片，來讓資料能正確讀取

經過 preprocess 的圖片



資料損毀的圖片



4. Experiment results

A. The highest testing accuracy

當我使用 pretrained 的 resnet18 時能達到最高 82.32 的 testing accuracy

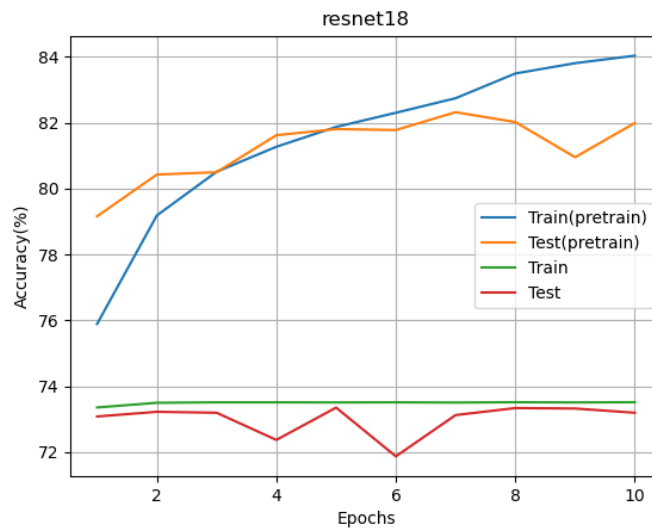
Hyper Parameters

- Batch size= 12
- Learning rate = 1e-3
- Epochs for ResNet-18 = 10
- Optimizer: SGD
- Momentum = 0.9
- Weight Decay = 5e-4
- Loss function: Cross Entropy Loss


```
18 Epoch 6
19 train accuracy: 82.30353075170842
20 test accuracy: 81.77935943060498
21 Epoch 7
22 train accuracy: 82.74487471526196
23 test accuracy: 82.3202846975089
24 Epoch 8
25 train accuracy: 83.49587129840546
26 test accuracy: 82.02135231316726
27 Epoch 9
28 train accuracy: 83.80908314350798
29 test accuracy: 80.95373665480427
30 Epoch 10
31 train accuracy: 84.0368735763098
32 test accuracy: 81.99288256227759
33
34 python lab4.py --model resnet18_pretrain --epochs 10 --batch-size 12 --lr 0.001
```

B. Comparison figures

● Resnet18



● Resnet50



5. Discussion

- 在這次的資料中，有發現資料損毀的情況發生，因為一開始沒有做特別的處理，所以導致一開始在實驗時有遇到一些困難，之後再做資料前處理時，我們應該提前想到可能有類似的情況發生，並且進行特殊的處理，來讓實驗能順利的進行。
- 在這次的實驗中，我有發現每一個 epoch 花的時間非常的久，一開始光一個 epoch 都要花到 9~10 hr，原本以為是 model 的問題，後來發現在調整 dataloader 中的 num_worker 數量後時間有明顯的下降，所以由此得知原來 training 時間的 bottle neck 是在 cpu 讀取資料的速度上，而不是 gpu。但是就算我把 num_worker 調到 4，一個 epoch 還是需要花到 1~2 hr，而就我觀察的原因還是在於 image 太大了，一個 image 的 resolution 差不多為 2000*2000。後來我就想到，既然每次 transform

都要做 `center crop` 跟 `resize`，那何不一開始就對所有 `image` 做前處理並且存起來，這樣讀取的 `image` 就是 `resize` 後的，速度也應該會加快很多。因此我最後的做法是提前對所有 `image` 做 `preprocess`，並儲存到另一個資料夾當中，而經過這樣處理過後，我發現每個 `training` 的 `epoch` 大約只需要花上 10 多分鐘，大幅降低了訓練的時間。

- C. 在做 `resize` 時，我也有嘗試不同的 `resolution`，一開始我是 `resize` 到 `256x256`，不過發現 `accuracy` 一直無法上升，後來改成 `512x512` 得到的 `accuracy` 就有比較高，由此可知 `image` 的 `size` 對於 `model` 的訓練以及預測還是有很大的影響。